

# Modelo de Predicción de Demanda y Maximización de Ingresos para Hoteles

# **TESIS**

QUE PARA OBTENER EL TÍTULO DE Maestro en Ciencia de Datos PRESENTA

Oscar Daniel Ezequiel Camarena Gómez

ASESOR David Lampón

MÉXICO, D.F.

2018

"Con fundamento en los artículos 21 y 27 de la Ley Federal de Derecho de Autor y como titular de los derechos moral y patrimonial de la obra titulada "Modelo de Predicción de Demanda y Maximización de Ingresos para Hoteles", otorgo de manera gratuita y permanente al Instituto Tecnológico Autónomo de México y a la biblioteca Raúl Baillères Jr., autorización para que fijen la obra en cualquier medio, incluido el electrónico, y la divulguen entre sus usuarios, profesores, estudiantes o terceras personas, sin que pueda percibir por tal divulgación una prestación"

Oscar Daniel E	Ezequiel Camar	ena Gómez
	Fecha	
	геспа	
	Firma	

# Resumen

# Abstract

# Índice general

1.	Introducción	1
2.	Marco teórico	6
3.	Metodología	30
4.	Diseño y Desarrollo	33
5.	Interpretación y Resultados	48
R.	oforoneos	52

# Índice de figuras

2.1.	Flujo de check-ins y check-outs para el día k.					26
1 1	Asignacion de inventario					4

# Índice de tablas

9.1	Modelog	۵۵	proposótico	nor	antogoría								1
Z.1.	Modelos	ae	pronosótico	por	categoria.								- 13

# Capítulo 1

# Introducción

Una práctica común dentro de la industria de la hotelería es la maximización del ingreso, mejor conocida como revenue management. Esta surge de la necesidad de poder obtener vender cada uno de los cuartos dentro del inventario al mayor precio posible y de esta manera poder maximizar el ingreso percibido por la porpiedad derivado de la venta de cuartos (El-Gayar N, et al. 2008). La técnica de revenue management tiene como base el análisis de información generada por la misma propiedad así como información ajena a ella para poder vender el producto adecuado, al cliente adecuado, en el momento y precio adecuados. Estas estrategias ayudan al hotelero en su gestión diaria de diversas maneras. Le permite establecer una estrategia coherente de precios a todos los niveles, controlar la distribución multicanal, realizar previsiones de la demanda, conocer mejor las necesidades y patrones de reserva de los diversos segmentos de clientes y disponer de más información sobre el mercado y el entorno que lo envuelve. Los sistemas de revenue management aplican principios básicos de economía para configurar los precios y el control del inventario que se pretende vender, de hecho, hay tres categorías básicas de administración de demanda que son utilizadas dentro del revenue management:

Decisiones Estructurales: Se decide qué formato de venta se va a utilizar; a qué segmento de mercado se va a dirigir la venta; cuáles serán las condiciones de la venta que se ofrecerán.

#### Capítulo 1: Introducción

- Decisiones de Precio: Cómo se asignará el precio para los elementos dentro del inventario; diferentes categorías de precios en el mismo inventario; cambios en los precios del inventario en el tiempo.
- Decisiones de Cantidad de Inventario: Se decide si se acepta o se rechaza una oferta de compra; cuanto inventario se destina a cada uno de los segmentos de mercado; cuando retirar un producto del mercado para venderlo posteriormente.

Tradicionalmente los hoteles utilizan los controles de decisión de cantidad de inventario como su estrategía por "default" (Aziz, et al. 2011), sin embargo la tecnología ha estado cambiando el mercado y la manera en que un hotel vende su inventario, ya que hoy en día los costos asociados al cambio de precio del inventario y el tiempo para distribuirlos ha bajado considerablemnte gracias a la adopción de un ecosistema totalmente electrónico (Bitran, Caldentey 2003). Antes del auge del revenue management la aerolínea British Airways experimentaba aplicando promociones en distintos productos dentro de su inventario para generar demanda en los asientos que sin esta promoción hubieran volado vacíos. Posteriormente la dirección de la aerolínea American Airlines dió un paso más adelante y crearon una practica llamada yield management, la cual se enfoca principalmente en maximizar los ingresos de cada ruta vendida mediante un control delinventario basado en análisis de la información histórica disponible. American Airlines hizo fuertes inversiones en lo que ellos llamaron yield management y lograron tener modelos de prónostico de demanda robustos, así como fuertes políticas de control de inventario y estrategías de sobreventa. Estas inversiones realizadas aunado al acto de desregularización de aerolíneas (1978) llevó a que American Airlines tuviera tarifas muy competitivas disponibles para el mercado, promoviendo una sana competencia entre las diferentes aerolíneas de la época. Luego del éxito de la implementación de las técnicas de yield management en las aerolíneas, otras industrias comenzaron a implementar este tipo de ténicas. Una de estas industrias fue la hotelera, la cuál cuenta con una problemática similar a la presentada en las aerolíneas: inventario perecedro, clientes reservando cuartos con tiempo de anticipación, competencia ofreciendo tarifas de bajo costo, y grandes esfuerzos para poder balancear la oferta y la demanda. Sin embargo, el problema presentado en la industria de hoteles es

#### Capítulo 1: Introducción

más complejo aún ya que se debe tener en cuenta que un cliente puede permanecer en la propiedad más de una noche, afectando la oferta del hotel en días posteriores a las llegadas a sus huéspedes. Las técnicas de revenue mangement / yield management han sido estudiadas y explotadas de manera exitosa en la industria de la aerolínea, sin embargo hay mucho trabajo por hacer aún en otras industrias, incluyendo la hotelera ya que en la medida en que esta técnica se afine los ingresos que este sector perciba por concepto de renta de habitaciones puede crecer sustancialmente. Los sistemas existentes de revenue management tienen dos componentes principales: un módulo que se encarga de pronósticar la ocupación del hotel en días futuros y un módulo que toma este pronóstico como base para recomendar precios para el inventario de tal forma que se maximice el ingreso total de la propiedad. Existen dos técnicas que son comúnmente utilizadas para hacer pronósticos de ocupación:

- Análisis de índicadores históricos: Se construyen modelos de series de tiempo con los principales indicadores del hotel (habitaciones ocupadadas, reservaciones recibidas, etc) que ayudan a entender la temporalidad del hotel y el comportamiento de la demanda de esa propiedad en días espécificos. Este tipo de análisis suele tener errores muy altos.
- Regresiones generalizadas, y modelos de machine learning: En los casos en dónde se cuenta con información desagregada del hotel (información de cada una de las reservaciones) es posible aplicar modelos más sofisticados como regresiones generalizadas o redes neuronales, en las cuales se puede modelar el comportamiento de la demanda del hotel utilizando toda la información disponible de la propiedad reduciendo los errores de los pronósticos arrojados por el modelo.

Es importante mencionar que una mejora del 10% en la exactitud del pronóstico de la ocupación puede llevar a un incremento de entre el 0.5% y 3.0% en el ingreso del hotel (Weatherford, et al. 2003), es por ello que resulta de gran interés la mejora continua de los módelos de pronóstico de ocupación.

# Objetivo

El objetivo de el presente trabajo es presentar una propuesta de modelo de pronóstico de ocupación y maximización de ingresos para hoteles, mismo que pudiera ser encapsulado dentro de un sistema de revenue management. El enfoque que se utilizó dentro de esta investigación para construír el modelo de pronóstico de ocupación fue la construcción de un modelo lineal generalizado (gracias a que se contaba con la información detallada de todas las reservaciones) cuyo resultado alimentaba a un segundo modelo que ofrece precios para tarifas y tipos de cuarto que maximizan el ingreso del hotel para una serie de fechas en el futuro.

Durante esta investigación se tuvo acceso a la base de datos de reservaciones para un hotel de negocios ubicado al sur de la Ciudad de México con información a partir del 01 de enero de 2015 hasta el 01 de agosto del 2018. También se utilizaron series de tiempo con el tipo de cambio del peso frente al dólar, una matriz de la calidad vs el precio de la propiedad y su set competitivo y un calendario de eventos de la plaza en la cuál se encuentra ubicado el hotel.

La primera etapa de la investigación consistió en realizar un análisis exploratorio de los datos, donde se detectó el nivel de limpieza, y comportamiento de las distintas variables de interés. Una vez concluído el análisis se generó un modelo de pronóstico de ocupación, el cual genera curvas de pickup de reservaciones y ajusta una regresión Poisson, la cual es un modelo líneal generalizado usado comúnmente en problemas de conteos de datos y tablas de contingencia. La regresión de Poisson asume que la variable de respuesta y tiene una distribución de Poisson y también asume que el logaritmo de su valor esperado puede ser modelado por una comibinación lineal de los parámetros desconocidos. Una vez obtenido el pronóstico de ocupación se alimenta al modelo de maximización de ingresos, el cuál resuelve un problema de optimización con restricciones teniendo como función objetivo la suma de los precios por habitación multiplicado por el porcentaje de ocupación pronosticado.

El modelo implementado en este trabajo de investigación tuvo un buen desempeño, se ejecutaron casos de validación y las curvas ajustadas por el modelo de pronóstico presentaron  $pseudo\ r\ cuadradas$  desde XX hasta XX y el MAPE observado fue de XX. Para el caso del modelo de maximización de ingresos se

#### Capítulo 1: Introducción

tuvo como resultado una matriz de precios contra días de anticipación a la fecha objetivo para un tipo de producto dentro del inventario. Esta matriz tiene como objetivo presentar diferentes precios en el tiempo desde X días antes de una fecha objetivo, de tal forma que mientras mayor sea la antelación con la que se reserva un cuarto, menor será el precio que se tenga que pagar por él. Durante las pruebas realizadas los precios que se obtuvieron estuvieron dentro del mercado competitivo de la propiedad estudiada.

En este trabajo de investigación se presentarán los resultados de ambos modelos y los detalles sobre las limitantes así como los siguientes pasos para poder robustecer aún más este modelo.

#### Justificación

Si bien los módelos de pronóstico de ocupación y los sistemas de revenue management han madurado a lo largo de más de 30 años de haber sido implementados por primera vez en distintas industrias, aún hay mucho trabajo por hacer ya que el poder de cómputo y la capacidad de procesamiento ha aumentado significativamente a lo largo del tiempo abriendo nuevas oportunidades y facilitando la implementación de técnicas sofisticadas para el manejo de datos y el modelado estádistico que puede ser de gran ayuda durante la implementación de este tipo de modelos.

El mercado hotelero es altamente dinámico, genera inmensas cantidades de información día con día, misma que es almacenada en servidores y pocas veces es utilizada para poder obtener una ventaja competitiva. De ser exitoso el modelo aqui implementado se podría aprovechar la investigación realizada para generar un marco de trabajo que ayude a este sector en partícular a aprovechar la información generada detrás de sus datos, de tal suerte que puedan obtener mayores ingresos por los servicios ofrecidos generando un ambiente de competencia sana entre los distintos jugadores de este mercado.

# Capítulo 2

# Marco teórico

En este capítulo se introducirá y discutirá el trabajo previo realizado y los conceptos necesarios para comprender las distintas técnicas y enfoques utilizados para la construcción de un módelo de predicción de demanda y maximización de ingresos así como el impacto que los resultados tienen dentro de la industria hotelera. Se dará una breve explicación del proceso de gestión de una propiedad mencionando cuales son los principales indicadores de control del proceso, así como las variables estudiadas para la toma de decisiones.

# Gestion de una propiedad

El proceso de gestión de propiedades o de hoteles comprende una serie de actividades que tienen como objetivo el garantizar la rentabilidad de un proyecto de arrendamiento. Dentro de las actividades que se llevan a cabo están las siguientes:

- Gestión de canales de venta
- Gestión de segmentos de mercado
- Gestión de precios por tarifa
- Análisis del comportamiento de la plaza

Análisis de indicadores principales

A continuación profundizaremos en cada una de las actividades que forman parte de este proceso.

#### Gestión de canales de venta

El equipo administrativo del hotel o propiedad, deben analizar diariamente el comportamiento de sus canales de venta o distribución. Típicamente un hotel tiene un catálogo estándar de canales de distribución:

- Sitio Web
- Call Center / FrontDesk
- Agencias de viajes en línea
- Globalizadores Agencias de viajes

Cada uno de los canales de venta van dirigidos a un segmento de mercado en específico y lo que el equipo de administración debe hacer es asegurar que la demanda del hotel se mantenga lo suficientemente alta para poder asegurar la continuidad operativa del negocio. Para lograr esto se genera una estrategia de distribución, en la cuál se designa parte del inventario a cada uno de los canales y se fija un precio a cada una de las tarifas a ofertar. Los precios para un producto en específico tienden a variar entre los diferentes canales y esto tiene que ver con el costo asociado a la operación de cada uno de los canales. Por ejemplo, el sitio web típicamente es un canal de reservación propio del hotel, lo que significa que las ventas generadas por este canal son libres de comisiones; por el contrario, las agencias de viajes en línea tienden a cobrar una comisión por la venta generada por esos canales.

Lo que la administración del hotel debe conseguir es poder tener la mezcla de ventas entre sus canales que maximice el ingreso, de tal forma que los costos generados por las ventas no *canibalicen* las ganancias de la propiedad. Es con esta restricción donde se descartaría una asignación total del inventario a las agencias de viajes en línea, ya que la comisión de este canal puede ser de hasta el  $25\,\%$  del total de la venta, lo cual podría representar una pérdida de hasta  $\frac{1}{4}$  de

las ganancias que se pudieron haber obtenido. Si por el contrario asignaramos todo el inventario disponible a los canales propios del hotel, si bien no se paga una comisión, la demanda generada por estos canales es inferior a la demanda generada por las agencias de viajes en línea.

### Gestión de segmentos de mercado

La gestión de los segmentos de mercado es similar a la gestión de los canales de venta ya que estos estan relacionados a los canales de distribución.

Las propiedades típicamente distinguen segmentan a sus clientes en las siguientes categorías:

- Clientes directos: Aquellos clientes que reservan en algún canal directo del hotel
- Clientes de negocios: Aquellos clientes que pertenecen a una empresa que tiene alguna tarifa convenida con el hotel. Típicamente esta tarifa esta sujeta a una producción de cuartos durante un periodo
- Clientes de mayoreo: Aquellos clientes que reservan utilizando un canal mayorista; puede ser una agencia de viajes en línea o mediante un agente de viajes.
- Grupos: Aquellos clientes que llegan a la propiedad como parte de un grupo.

Para gestionar eficientemente los segmentos de mercado se debe crear una estrategia de asignación de precios a las diferentes tarifas que van dirigidas a cada uno de ellos. Por ejemplo, un *cliente directo* que llega al hotel sin reservación, es propenso a pagar un precio mas alto por una habitación disponible, al contrario de un cliente que viene como parte de un grupo que reservó con mayor tiempo de anticipación con una tarifa mucho mas baja. El equipo administrativo debe cuidar los segmentos de mercado que ocupan la propiedad ya que el tener un grupo muy grande ocupándola significa muchas veces tener un hotel lleno a una tarifa muy baja y con mayor desgaste en las habitaciones, y por el otro lado, no siempre es posible llenar un hotel con clientes que llegan sin reservación los cuales están dispuestos a comprar una habitación a un precio mas elevado.

# Gestión de precios por tarifa

Una de las actividades mas importantes del proceso de gestión de una propiedad es la gestión de los precios por tarifa ya que generalmente las tarifas disponibles en un hotel están asociadas a un segmento de mercado y a un canal de reservación. Para poder realizar esta actividad se debe establecer una estrategia en la cual se define si se quiere incrementar la ocupación de la propiedad o si se quiere incrementar el RevPAR (revenue per available room). Una vez establecida la estrategia inicial se deben modificar los precios para las tarifas que impactan los canales y segmentos donde se quiere fomentar la demanda o incrementar el precio. Si el objetivo es el primero, lo mas probable es que el cambio emplique una baja en las tarifas o creación de promociones sujetas a diversas restricciones, en cambio, si el objetivo es el segundo muy probablemente el cambio implique una alza en algunas tarifas y el cierre de algunas tarifas en donde este incremento no se pueda llevar a cabo por temas contractuales, por ejemplo las tarifas convenidas con otras empresas o clientes.

Es importante mencionar que la ejecución de esta tarea dentro del proceso de gestión depende del análisis continuo de la información histórica generada por el hotel (comportamiento de la propiedad en años anteriores en la misma fecha sujeta al estudio), conocimiento de la plaza en donde se ubica la propiedad (depende de la experiencia del equipo administrativo del hotel), información ajena al hotel (situación marco económica, eventos cercanos a la plaza, desempeño de la competencia cercana a la propiedad, etc). Muchas veces el conocer esta información implica un gran esfuerzo por parte del equipo ya que la información tiende a estar distribuída en diversos sistemas o en ocasiones deberán recabarla físicamente (visitando a su competencia o haciendo llamadas telefónicas) dejando un riesgo latente de recibir información que no es precisa.

Otra de las fuertes dependencias para la ejecución efectiva de esta tarea es contar con sistemas que distribuyan los nuevos precios en todos los canales disponibles en poco tiempo y con poco esfuerzo ya que de lo contrario no tendria sentido realizar esta labor si al final los precios no pueden ser cambiados dentro de un tiempo en el que el mercado pueda responder de acuerdo a lo planeado durante el análisis de la información. Una vez que los precios son alterados, el equipo deberá analizar nuevamente la información para asegurar que los cambios tuvieron los

efectos deseados, de lo contrario, se deberá cambiar la estrategia lo antes posible para evitar afectar el desempeño de la propiedad.

#### Análisis del comportamiento de la plaza

En el sector de la hotelería en México, se le llama plaza a la ubicación geográfica en dónde se encuentra una propiedad y típicamente agrupa a propiedades independientes o de otras marcas (set competitivo), oficinas, corporativos, centros comerciales, y lugares de interés turístico. La plaza genera gran cantidad de información que es de interés para el equipo administrativo de una propiedad, ya que el desempeño financiero de esta depende mucho de la situación que presenta la plaza en un momento determinado.

Los hoteles que comparten una plaza generalmente están dispuestos a compartir información de su propiedad con otros, de esa forma pueden tener un conocimiento mas amplio sobre la realidad que se vive en ella. Si una propiedad requiere obtener datos de su competencia, basta con una simple llamada telefónica a la propiedad de interés para solicitar los datos de interés, por ejemplo: cuartos ocupados, cuartos disponibles, cuartos fuera de servicio, ingresos generados por la venta de habitaciones. Con esta información se pueden calcular algunos indicadores que son indispensables para el analisis del comportamiento de la plaza:

- % de Ocupación:  $\frac{cuartos\ ocupados}{cuartos\ disponibles}$
- $\blacksquare$  ADR (Average Daily Rate o Tarifa Promedio):  $\frac{ingresos}{cuartos\ ocupados}$
- $\blacksquare$  RevPAR (Revenue per available room o Tarifa Efectiva):  $\frac{ingresos}{cuartos\ disponibles}$

Para poder conocer la situación de una propiedad frente a la competencia en una plaza se generan otros indicadores que facilitan este tipo de análisis.

- $\blacksquare$  Penetración de ocupación:  $\frac{\%\ ocupacion}{\%\ ocupacion\ plaza}$
- $\blacksquare$  Penetración de tarifa:  $\frac{tarifa\ promedio}{tarifapromedio\ plaza}$

El hotel o propiedad que cuente con los valores mas altos para estos indicadores será el hotel con mayor demanda y mayores ingresos dentro de la plaza, sin

embargo, para que el análisis sea efectivo se debe escoger al set competitivo de manera adecuada, de tal forma que los hoteles contenidos dentro de este set sean de la misma gama y vayan dirigidos al mismo público objetivo.

#### Análisis de indicadores principales

Como se mencionó anteriormente, existen indicadores de desempeño de una propiedad u hotel que deben ser estudiados de manera diaria para poder tomar decisiones que mejoren el desempeño de esta, asegurando una continuidad operativa y la rentabilidad del inmueble:

- % ocupación
- ADR
- REvpar

Típicamante durante el análisis realizado, se compara el desempeño de cada uno de estos indicadores de manera diaria, mensual y anual, comparando los valores contra el año anterior y buscando siempre una variación positiva entre años. En caso de tener variaciones negativas se debe buscar la causa de esta variación. Se puede tratar de una baja en la demanda general de la plaza, un periodo de recesión financiera generalizada, un nuevo competidor en la plaza, etc. Una vez identificado la causa se deben tomar las acciones necesarias para generar demanda a la propiedad en cuestión. Típicamente la forma más efectiva de hacerlo es modificar los precios de tal forma que el mercado responda favorablemente sin afectar la rentabilidad del inmueble.

# Antecedentes: Modelos de Revenue Management

Podemos definir la práctica de revenue management como la aplicación de técnicas analíticas que intentan predecir el comportamiento de un consumidor al nivel de un micro mercado, optimizando la disponibilidad de productos y sus precios de tal forma que maximicen el crecimiento de los ingresos. El principal objetivo de esta práctica es vender el producto indicado al cliente indicado al tiempo indicado en el precio indicado. La escencia de esta práctica radica en entender

la percepción del producto que tienen los clientes y alinear los precios de estos productos de acuerdo a esta haciendo una correcta segmentación de los clientes objetivos.

Es importante mencionar que la disciplina de *revenue management* se compone de dos partes principales:

- 1. Pronóstico de ocupación
- 2. Asignación de precios

En las siguientes secciones discutiremos acerca de los trabajos previos sobre los dos principales componentes de esta disciplina.

# Trabajo previo: modelos de pronóstico de ocupación

La base de una práctica efectiva de revenue management es un buen modelo de pronóstico de demanda, ya que el resultado de este será la entrada del modelo de optimización de precio de tal suerte que mientras menor sea el error en el pronóstico de la demanda, mejor será la optimización de los precios para cada uno de los productos sujetos al análisis.

Se tiene registro de trabajo previo para el desarrollo de modelos de pronóstico de demanda en diferentes industrias, algunas de ellas son: *líneas aéreas*, *retail*, *telecomunicaciones* y *hospitalidad*, siendo la primera la que cuenta con modelos de pronóstico más maduros, este hecho obedece a que en esta industria es en dónde a principios de los años 80's nace la disciplina de *revenue management*.

La venta de asientos en un vuelo es un caso dónde naturalmente se puede utilizar un modelo de optimización de ingresos ya que cuenta con ciertas características que hacen que el modelado del problema sea muy intuitivo:

- Se cuenta con un inventario reducido
- El inventario es perecedero (una vez que el avión despega, los asientos vacíos no generan un ingreso
- Se cuenta con un amplio segmento de mercado que genera demanda sobre el producto

- Los asientos se compran con distintos tiempos de anticipación (hay clientes que compran con un mayor tiempo de anticipación que otros)
- Se conoce el tiempo de estancia de cada uno de los clientes en la aeronave.

Las condiciones mencionadas anteriormente facilitan la construcción de un modelo de pronóstico de demanda. A continuación haremos una breve descripción de la evolución de este tipo de modelos a lo largo del tiempo.

Beckmann y Bobkowski (1958) presentaron modelos estadísticos que describen reservaciones de pasajeros, cancelación de reservaciones y no shows. En su trabajo los autores comparan modelos utilizando diferentes distribuciones probabilísticas: Poisson, Binomial Negativa y Gamma aplicadas en datos generados por aerolineas con la finalidad de modelar las reservaciones efectivas y propone una condicion optima para un nivel de sobreventa para un vuelo en partícular.

Posteriormente, otros autores continuaron explorando nuevas metodologías para poder construír modelos de predicción de demanda. Uno de los autores mas citados en las investigaciones de modelos de pronóstico de demanda es Lee (1990) que presenta un artículo en donde explica don enfoques para resolver el problema de pronóstico de ocupación en aerolíneas:

- Modelos de series de tiempo
- Modelos basados en información de reservaciones

Los modelos basados en series de tiempo consideran unicamente las series de tiempo con la información de llegadas o porcentajes de ocupación aplicandoles modelos de series de tiempo (como suavizamiento exponencial, ARIMA, etc). En estos casos no se utiliza la información propia de las reservaciones.

El enfoque basado en reservaciones hace uso de la información contenida en las reservaciones para pronosticar llegadas futuras. En este tipo de modelos típicamente se considera el concepto de pick-up. Esto quiere decir que dadas K reservaciones para un dia futuro T, esperamos tener un pick-up de N reservaciones más desde este momento hasta el momento T. El pronóstico entonces será K+N

Existen dos versiones del modelo de *pick-up* (Weatherford y Kimes, 2003). La versión aditiva del modelo en donde a las reservaciones registradas en el hotel se

le suman el promedio de reservaciones que típicamente llegan en un periodo entre la fecha actual y la fecha de llegada del huésped (tomando la temporalidad del hotel en cuenta), y la versión multiplicativa, la cual es muy similar, con la única diferencia de únicamente se toma en cuenta una fracción de las reservaciones actualmente registradas en el hotel.

Existen trabajos en los cuales se presenta un modelo avanzado en el cual se combinan modelos de series de tiempo y modelos basados en reservaciones, tal es el caso del artículo presentado por Flides y 0rd (2002) en el cuál se concluye que la combinación de ambos modelos generalmente tienen un mejor desempeño en cuanto al pronóstico de la demanda. Otro trabajo que presenta un enfoque similar es el realizado por Sa (1987) en el cuál se utiliza una regresión multiple para desarrollar un modelo de pronóstico combinado, en este caso, la variable dependiente eran las reservaciones pendientes por llegar mientras la variable independiente incluía el número de resrvaciones confirmadas, un índice de temporalidad, índice semanal y un promedio del comportamiento histórico de las reservaciones pendientes. Esta regresión se corría para varios días antes de la llegada de los clientes ( $t=7,\,14,\,21,\,y\,28$ ).

Es importante hacer las siguientes observaciones sobre los modelos comentados anteriormente:

- Los modelos de regesión lineal asumen que existe una correlación entre el número de reservaciones confirmadas y el número final de reservaciones (en el día 0), de tal forma que:  $pronostico_{dia0} = a + b * reservaciones_{diaN}$
- Los modelos de regresión logarítmica asumen que existe una correlación entre el número de reservaciones confirmadas y el número final de reservaciones (en el día 0), de tal forma que:  $log(pronostico_{dia0} = a + b * log(reservaciones_{diaN})$
- El modelo aditivo suma las reservaciones actuales al promedio histórico del pickup de reservas desde el día de la lectura diaN hasta el dia de la estancia dia0:  $pronostico_{dia0} = reservas_{diaN} + \sum_{i=0}^{n} \frac{pickup_i}{n}$
- El modelo multiplicativo multiplica las reservaciones actuales por la proporción del promedio histórico de reservaciones desde el diaN hasta el dia de la estancia  $dia\theta$ :  $pronostico_{dia0} = reservas_{diaN} * \frac{reservas_n \sum_{i=0}^{n} \frac{pickup_i}{n}}{reservas_n}$

Categoria	Modelo
	1. Mismo día año anterior
Historico	2. Promedios móviles
THStorico	3. Suvizamiento exponencial
	4. ARIMA
Avanzado	1. Aditivo
	a. Pickup Clasico
	b. Pickup Avanzado
	2. Multiplicativo
	a. Curva de reservaciones
	1. Promedios ponderados de modelo histórico y modelo avanzado
Combinados	2. Regresión
	3. Modelo de información completa

Tabla 2.1: Modelos de pronosótico por categoría

La tabla 2.1 resume los modelos más comunes utilizados para pronosticar ocupación, agrupados por categoría.

#### Desempeño de modelos de pronóstico

Se han realizado estudios con el objetivo de comparar el desempeño de los modelos previamente presentados, a continuación presentaremos los resultados obtenidos.

Wickham (1995) estudió la efectividad de una variedad de modelos de pronóstico de ocupación utilizando datos de aerolíneas. Durante este trabajo se comparan modelos históricos de ocupación (utilizando promedios simples y promedios ponderados) y modelos de *pickup* (clasicos y avanzados) llegando a la conclusión de que los segundos son más efectivos, al menos para los datos aplicados durante su análisis.

Weahterford (1998) comparó los modelos aditivos frente a los modelos multiplicativos y modelos de regresión dentro del contexto de las aerolíneas y encontró que los modelos aditivos y de regresión tienen un mejor desempeño que los multiplicativos.

# Modelos de machine learning

Si bien las técnicas estadísticas anteriormente mencionadas pueden predecir efectivamente níveles de ocupación y demanda, se requieren de amplios conocimientos en estadística y de largos procedimientos para poderlas aplicar de manera tal que funcionen correctamente o de otra manera se puede optar por el uso de software comercial el cuál resulta muy costoso la mayoría de las veces. Para solventar estos hechos, algunos autores presentan un enfoque diferente para construír modelos de predicción de ocupación, tal es el caso de Caicedo-Torres, Payares (2016) quienes proponen el uso de algorítmos de Machine Learning para construír modelos predictivos de ocupación y demanda en la industria de la hospitalidad. La ventaja de estos modelos es que estan listos para ser utilizados por el staff administrativo de la propiedad sin la necesidad de contar con amplios conocimientos de estadística. Además, estos modelos tienen la ventaja de poder ser empaquetados dentro de aplicaciones de bajo costo, o de ser ejecutados en una infraestructura basada en la nube, lo cual significan soluciones rentables para el sector de hospitalidad.

A continuación presentaremos a detalle algunos algorímtos de M.L. utilizados para la construcción de este tipo de modelos.

#### Regresión de Ridge

La regresión de ridge es un algorítmo de regresión que incluye un término de regularización en su función de costos con el fin de lograr una mejor aproximación al momento de generalizar el modelo. La regresión de Ridge penaliza el algorítmo con un factor proporcional a la norma Euclidiana (L2) del vector de parámetros.

$$J(\theta) = \sum_{i=1}^{n} (\theta^T x_i - y_i)^2 + \alpha ||\theta||^2$$

Dónde el factor de regularización  $\alpha$  controla la importancia relativa de la penalidad compleja. Para optimizar esta ecuación se debe encontrar la derivada de la función de costos e igualarla a cero, de tal forma que el vector de parámetros que minimza el error es:

$$\theta = (X^T X + \lambda I)^{-1} X^T y$$

Las nuevas predicciones se pueden calcular como sigue:

$$h(X) = \theta^T x = \sum_{i=1}^n \theta_i x_i$$

#### Ridge Regresión con Kernel

Este método consta de aplicar el truco del Kernel a la regresión previamente comentada, esto con la finalidad de projectar los datos originales en un espectro de variables sin tener que explicitamente calcular las transformaciones. Para esto, se comienza con el vector de pesos optimizados para la Regresión de Ridge:

$$\theta = (X^T X + \lambda I)^{-1} X^T y$$

Se manipula algebraícamente para obtener:

$$\theta = X^T (XX^T + \lambda I)^{-1} y$$

De tal forma que una predicción puede ser obtenida por:

$$h(x') = \theta^T x' = y^T (XX^T + \lambda I)^{-1} Xx'$$

Una función de Kernel evalúa a un producto punto de la forma

$$f(x_1, x_2) = \phi(x_1) \cdot \phi(x_2)$$

sin tener que explícitamente calcular la transformación  $\phi$ . Si definimos  $K_{i,j} = f(x_i, x_j)$  y  $k_i = f(x_i, x')$ , donde  $x_i$  es la iésima fila de la matriz X, entonces

$$h(x') = \theta^T x' = y^T (K + \lambda I)^{-1} k$$

Ajustamos un modelo en un espacio dimensional mayor inducido pro  $\phi$  sin tener que incurrir en una complejidad computacional adicional. Se pueden utilizar varios Kernels, entre los más populares están el Kernel polinomial

$$k(x_1, x_2) = (\gamma x_1^T x_2 + \beta)^{\delta}$$

Y el Kernel Gaussiano

$$k(x_1, x_2) = exp(-\frac{||x_1 - x_2||^2}{2\delta^2})$$

#### Red neuronal multicapa

Una red neuronal es un modelo de M.L. capáz de clasificar y realizar regresión. Esta compuesta por n capas totalmente conectadas de neuronas artificiales formando un grafo conectado (en el caso más simple se tiene una capa oculta y una capa de salida). En este modelo, la salida de cada capa de neuronas será la entrada de la siguiente capa. La función de activación es dada por la siguiente ecuación

$$y = f(\sum_{i=1}^{n} w_i x_i + b)$$

donde f es una función de activación. Entre las opciones más populares se encuentran la sigmoide  $y=(1+exp(-x))^{-1}$  y la función lineal y=x. La elección de la función de activación en la capa de salida define el tipo de red neuronal (si clasifica o realiza regresión)

Las redes neuronales son entrenadas mediante un algorítmo llamado propagación hacia atrás (backpropagation) que es una aplicación del algorítmo de descenso por gradiente que toma en cuenta la contribución de las neuronas de la capa oculta al error E

#### Red neuronal de base radial

Las reded nueronales de base radial (RBF) usualmente tienen una sola capa oculta que emplea una serie de funciones llamadas funciones de base radial como detectores de características. Las redes RBF pueden ser utilizadas para realizar regresiones o clasificaciones. En este modelo la capa oculta utiliza funcion gaussiana como función de activación  $\phi$ :

$$\phi_j(x) = exp(-\frac{||x - \mu_j||^2}{2\sigma_j^2})$$

Y como función de salida, se tiene la siguiente ecuación:

$$y(x) = \sum_{j=0}^{M} w_{kj} \phi_j(x)$$

donde  $w_{kj}$  es el vector de pesos que conecta la neurona j de la capa oculta con la neurona k de la capa de salida.

El entrenamiento de este tipo de modelos consiste en encontrar un conjunto de valores para los parámetros  $\mu_j$ ,  $\sigma_j$  y  $w_{jk}$  que maximizan el desempeño de la red.

# Desempeño de algoritmos de M.L.

Para realizar el entrenamiento, validación y pruebas de estos modelos se utilizó un proceso de *Cross Validation* en cada uno de los data sets. Los pronósticos se hicieron para un día posterior y para 7 días posteriores, midiendo el desempeño del modelo utilizando la medida *MAPE* (Mean Absolute Percentage Error) definida como:

$$MAPE = \frac{1}{n} \sum_{t=1}^{n} |\frac{y_t - h_t}{y_t}|$$

Los resultados mostraron que la regresión de Ridge una transformación polinomial de grado dos tuvo el mejor desempeño con un MAPE del  $8.2012\,\%$  durante la validación y un MAPE del  $8.6561\,\%$  durante las pruebas. Durante el proceso de pruebas no se tuvo evidencia de sobreajuste del modelo.

Por otra parte el modelo la regresión de Ridge con Kernel tuvo un MAPE de 8.69622% durante la validación, seguido por la red neuronal con un MAPE del 12.89174% y finalmente la red neuronal RBF con un MAPE de 26.32086%.

Los resultados obtenidos durante esta investigación fueron bastante prometedores sustentando el uso de modelos de M.L. como modelos de caja negra para estimar la ocupación futura de una propiedad, sin requerir conocimiento o experiencia estadística del estaff del hotel, permitiendo nuevos avances el las técnicas de revenue management en el sector de hospitalidad.

#### Modelos de Big Data

En el sector de turismo y hospitalidad se han hecho esfuerzos para obtener modelos de pronóistico de llegadas y ocupación basados en información generada a partir de las búsquedas en páginas web y el tráfico generado en ellas. Si bien, los resultados obtenidos han confirmado la validéz de algunas fuentes de datos generados en línea, poco trabajo se ha hecho cruzando diferentes fuentes de datos, por ejemplo, utilizar los datos de las búsquedas realizadas en *Google* combinados con el tráfico generado en el sitio web del hotel, los cuales deben

estar altamente correlacionados (Tierney y Pan 2012).

Existen algunos trabajos en donde se adoptan dos métodos principales para obtener la ocupación de un hotel a partir de datos generados en línea. Los metódos utilizados son: Promedios móviles integrados autoregresivos con variables externas y Modelo de regresión dinámica con cambios Markov (MS DR)

En el estudio presentado por Pan y Yang (2017) se presentan dos modelos de series de tiempo en el que se incoroporan tres fuentes de información generada en línea para predecir la ocupación de un hotel. Los datos de entrada contenían datos que describían:

- Tráfico generado en el sitio web de la propiedad
- Información relacionada con las peticiones realizadas a los motores de búsquedas (Google)
- Información del clima en el destino en dónde se ubica la propiedad

El primer modelo presentado es un modelo ARMAX en donde se utilizan variables generadas con big data como predictores directos de la ocupación. El modelo se definió de la siguiente manera:

$$y_t = \alpha + x_t \beta + \mu_t$$
$$\mu_t = \sum_{i=1}^m \rho_i \mu_{t-i} + \sum_{j=1}^n \theta_j \epsilon_{t-j} + \epsilon_i$$

donde  $y_t$  es la variable dependiente y  $x_t$  es un vector de variables exógenas independientes. Si  $\beta$  es igual a 0, el modelo se convierte en un modelo ARMA(m,n) estándar.

El segundo modelo presentado en este trabajo es el MSDR específicado como:

$$y_t = \tau_s + x_t \alpha + z_t \beta_s + \epsilon_s$$

dónde  $\tau_s$  es el estado de intercepción;  $x_t$  es un vector de variables exógenas con coeficientes independientes del estado;  $z_t$  es un vector de variables exógenas con coeficientes dependientes del estado  $\beta_s$ ;  $\epsilon_s$  es un error normal i.i.d con media 0 y una varianza dependiente del estado de  $\sigma^2$ . Este modelo permite a las variables en el vector  $z_t$  con parámetros dependientes del estado tomar diferentes

comportamientos basados en el estado que responden a un proceso de Markov con J estados y una probabilidad transicional  $p_{ij}$  específicada como sigue:

$$p_{ij} = \frac{1}{1 + \sum_{m=1}^{k} exp(-q_{im})} \ si \ j = k$$

$$p_{ij} = \frac{exp(-q_{ij})}{1 + \sum_{m=1}^{k} exp(-q_{im})} \ si \ j \neq k$$

donde  $q_{ij}$  es el parámetro transformado definido como

$$q_{ij} = -log(\frac{p_{ij}}{p_{ik}})$$

Para empezar con la estimación del modelo se utiliza el algorimto EM expectationmaximization el cuál arroja el valor inicial. Posteriormente se predicen las probabilidades de cada uno de los estados y actualizando la verosimilitud en cada
paso. Un paso clave de esta estimación es el cálculo de la verosimilitud de los
estados latentes la cual es obtenida mediante la iteración de la verosimilitud
condicional.

Para medir el desempeño de ambos modelos se utilizó la medida MAPE

$$MAPE = \frac{1}{n} \sum_{t=1}^{n} |\frac{y_t - h_t}{y_t}|$$

Los resultados arrojan que el modelo ARIMAX tuvo un mejor desempeño con un MAPE del 3.804 % comparado con el 4.714 % obtenido por el modelo MS DR

Se puede concluír que los modelos basados en big data presentan una alternativa para poder generar pronósticos de ocupación y demanda utilizando información exógena a los hoteles, sin embargo se debe tomar en cuenta que el costo asociado a la configuración y puesta en marcha de este tipo de modelos es alto ya que se debe de contar con una infraestructura que pueda soportar el manejo de grandes volúmenes de información.

# Modelos de optimizacion de ingresos

Recordemos que un systema de gestión de ingresos para un hotel se puede clasificar dentro de dos grandes grupos (Abdel Aziz et al, 2011). En el primer grupo

tendremos todos los sistemas que controlan la cantidad de inventario que se ofrece a cada segmento de cliente. Es decir, se asigna dinámicamente un porcentaje de inventario con un precio fijo distinto para cada uno de los segmentos estudiados por el hotel. El segundo grupo se distingue por asignarle un precio de manera dinámica al inventario que cuenta con características similares. El precio será ajustado continuamente en el tiempo basando los cambios en las variaciones de la oferta y la demanda del producto.

En esta sección se presentaran los módelos utilizados en trabajos anteriores para poder asignar precios dinámicos a un inventario con el fin de maximizar los ingresos de una propiedad.

## Modelo de multiplicadores de precio

El módelo de multiplicadores de precio propone un enfoque sencillo para resolver el problema de maximización de ingresos de una propiedad.

Este modelo propone tener un precio base de referencia (dependiendo de la temporalidad del hotel) y modificarlo utilizando un conjunto definido de multiplicadores (cuyo valor se encuentra alrededor del 1) y que son infulenciados por variables sensibles a la operación de la propiedad, por ejemplo el % ocupación, el tiempo de antelación de una reserva, etc., de tal forma que cada multiplicador ajusta el precio por encima o por debajo del precio de referencia.

El objetivo de este modelo es maximizar los ingresos de la propiedad tomando en cuenta la demanda y la elasticidad del precio. Este modelo tiene la ventaja de enmarcar el pecio en términos de *primas* o *descuentos* en un tiempo variable o sobre un precio de referencia temporal definido por el staff de la propiedad y al ser un modelo muy sencillo de entender permite que el gerente de la propiedad transimita un poco de su experiencia al modelo al ser el quien define el precio de referencia para cada una de las temporadas del hotel.

En trabajos previos se pronponen las siguientes variables que influencían le efecto en los precios:

- Tiempo de antelación de una reserva
- Habitaciones disponibles al momento de crear una reservación

- Tiempo de estancia de una reserva (LoS)
- Número de cuartos reservados (tamaño de grupo)

A partir de estas variables de influencia se construyen multiplicadores (1 multiplicador por cada variable). Para simplificar la formulación del problema, los multiplicadores usualmente sonn formulados como funciones lineales de las variables de influencia. Las funciones lineales son elegidas tomando en cuenta una relación lógica entre las variables de influencia y el comportamiento de la propiedad, por ejemplo, si al momento de hacer una reserva hay una alta disponibilidad de habitaciones entonces se esperaría que el multiplicador del precio lo haga bajar con la finalidad de incrementar la demanda de la propiedad.

El modelo recomendará un precio tomando en cuenta el precio de referencia dado por el gerente de la propiedad y los multiplicadores utilizando la siguiente fórmula:

$$Precio_{final} = P_{Referencia} * M_{tiempo} * M_{capacidad} * M_{LoS} * M_{Grupo}$$

Como se puede observar, este modelo es sencillo, sin embargo tiene algunas limitantes:

- Las funciones lineales de los multiplicadores deberán ser afinadas continuamente
- Todo el modelo depende de la elección de un precio inicial dado
- Se debe estimar la elasticidad del precio, esta estimación tendrá un error

Sin embargo, una gran ventaja de este modelo es la forma transparente en la que opera, permitiendo que el equipo administrativo de las propiedades se familiarice con estos sistemas.

### Modelo de maximización sujeto a restricciones

Un hotel tipicamente designa un conjunto definido de categorías de precio, posteriormente asigna un inventario a cada categoria, de tal forma que las reservaciones que se hacen con un mayor tiempo de anticipación reciben un precio

mas bajo y conforme el inventario se va agotando se reservan las habitaciones con una categoría de precio mayor. El problema con este enfoque radica en que si se asigna un gran número de cuartos a la categoría de precios mas baja, se tendrá un gran número de reservaciones pero a costo de una pérdida en el ingreso generado, y por el contrario, si se asigna un mayor número a la categoría con el precio mas alto se dejaran mas cuartos sin vender.

Este tipo de modelos permite al equipo que administra la propiedad encontrar el precio óptimo para cada categoría en cada noche de tal forma que el ingreso se maximice. Esto conlleva a un sofisticado problema de optimización que tome en cuenta las reservaciones futuras y su probabilidad de ocurrencia. Los precios son dinámicos y cambian día con día. Hay que mencionar que para que este modelo sea certero depende de una buena estimación de la demanda futura de los cuartos.

Para formular el modelo, se define una estancia por los parámetros (a,L), dónde a es la primera noche de estancia y L es la duración de la estancia, de tal forma que el modelo queda definido como sigue:

Maximizar

$$\sum_{l=1}^{Max} {}^{l} P_{l} O_{l}$$

Sujeto a

$$O_l < C_l \ \forall l$$

$$P_l \ge 0 \ \forall l$$

Dónde las variables de decisión del modelo son:

 $P_l$ : Precio para la noche  $l \ \forall l$ 

Y las variables auxiliares:

 $X_{a,L}$ : El numero de cuartos asignado a una estancia del tipo (a,L) definido como:

$$X_{a,L} = d_{a,L} \left( \frac{\sum_{l=a}^{a+L-1} P_l}{L * P_{nominal}} \right)^e$$

 $O_l$ : Es el número de habitaciones reservadas para una noche dada y está definida como sigue

$$O_l = \sum_{a, L \in N_l} X_{a, L}$$

Y las entradas del modelo:

 $P_{nominal}$ : Precio nominal de la propiedad (usualmente la tarifa promedio histórica)

e: Elasticidad entre precio y demanda

 $d_{a,L}$ : La demanda de la estancias tipo a, L

 $N_l$ : El número de estancias que utilizan la noche l

 $C_l$ : El número de cuartos disponibles en el hotel

La salida de este modelo serán los precios optimos para cada noche.

Es importante notar que este modelo conlleva un sofisticado problema de optimización que requiere un poder de cómputo considerable para poder ser resuelto y además se debe iterar sobre distintos valores para el parámetro de elasticidad para encontrar el valor que garantice una solución factible del problema.

## Modelo de optimización de redes

El modelo de optimización de redes es una formula de programación estocástica que permite capturar la aleatoreidad de la demanda desconocida, por ejemplo, el número de llegadas a la propiedad para cierto día o la longitud de estancia para una reserva dada)

Antes de entrar al detalle de este tipo de modelos debemos de tomar en cuenta la siguiente notación:

- $x_{i,j}$  es el número de reservaciones confirmadas para hacer *check-in* en el día i y para hacer *check-out* en el día j, dónde  $0 \le i \le j \le T$ . i=0,1,2,...,T-1 es el índice de tiempo para *check-in* y j=1,2,3,....,T es el índice para *check-out*
- C es la capacidad total del hotel (Cuartos disponibles).
- $R_{i,j}$  es el ingreso ganado por la reservación con *check-in* en el día i y *check-out* en el día j.
- $U_{i,j}$  es la demanda de reseravs con *check-in* del día i y *check-out* el día j.

Nótese que:



Figura 2.1: Flujo de check-ins y check-outs para el día k.

- $\sum_{j=i+1}^{T} x_{i,j}$  es el número de *check-ins* en el día *i*.
- $\sum_{i=0}^{j-1} x_{i,j}$  es el número de check-outs en el día j.

Se asume que no hay clientes con estancias en días anteriores al día 0 y que todos los clientes salen del hotel antes, o en el día T. También se asume que cualquier cliente debe permanecer en el hotel por lo menos una noche.

#### Formulación de red estocástica

Los *check-ins* y *check-outs* pueen ser modelados como flujos de entrada y de salida de los nodos en una red. En la figura 2.1 se considera un día particular, el día k (k = 1, 2, ..., (T - 1)).

La siguiente ecuacion modela la ocupacion del hotel para el día k con k = 1, 2, 3, ..., (T-1):

$$\sum_{i=0}^{k-1} \sum_{j=k+1}^{T} x_{i,j} + \sum_{j=k+1}^{T} x_{k,j} - \sum_{i=0}^{k-1} x_{i,k}$$

Debemos considerar también que el hotel tiene una capacidad limitada, por lo tanto se tienen las siguientes restricciones para el día k:

$$\sum_{i=0}^{k-1} \sum_{j=k+1}^{T} x_{i,j} + \sum_{j=k+1}^{T} x_{k,j} - \sum_{i=0}^{k-1} x_{i,k} \le C$$

Para el día 0, se asume que no hay *check-outs* ni estancias que crucen a ese día, de tal forma que se tiene la siguiente ecuación para el día 0:

$$\sum_{j=1}^{T} x_{0,j} \le C$$

El modelo de optimización se define como sigue:

Maximizar:

$$\sum_{i=0}^{T-1} \sum_{j=i+1}^{T} R_{i,j} x_{i,j}$$

Sujeto a:

$$\begin{split} \sum_{i=0}^{k-1} \sum_{j=k+1}^{T} x_{i,j} + & \sum_{j=k+1}^{T} x_{k,j} - \sum_{i=0}^{k-1} x_{i,k} \leq C \\ & \sum_{j=1}^{T} x_{0,j} \leq C \\ & x_{i,j} \leq U_{i,j} \\ & x_{i,j} \geq 0 \\ & \forall 0 \leq i < j \leq T \end{split}$$

Si bien este problema pareciera ser un problema de integración lineal, se debe considerar que los parámetros  $U_{i,j}$  son desconocidos al inicio del periodo de planeación. Mas aún, los ingresos pudieran no ser fijos como se quisiera ya que recordemos que se pueden fijar distintos precios para la misma habitación, lo que puede resultar en una variación de la demanda del producto. Una manera de resolver este problema pudiera ser reemplazando los parámetros por su mejor estimador puntual, en primera instancia utilizando la esperanza de  $E(U_{i,j})$ .

Muchas veces utilizando este método se pueden obtener resultados razonables, sin embargo esto no siempre garantiza una solución factible y para solucionar esto se han utilizado otras herramientas como la *Optimización Robusta* que es un enfoque proactivo usado para resolver problemas estocásticos.

#### Resumen

Los modelos de optimización de ingresos han tenido un gran avance en la industria de las aerolíneas, sin embargo, aún hay un trecho muy largo por recorrer

para poder aplicarlos con el mismo nível de maduréz en la industria de la hotelería.

Como se revisó anteriormente, existen muchas propuestas de enfoques diferentes para la implementación del modelo de optimización de ingresos en hoteles y la elección de alguno de ellos dependerá de los siguientes factores:

- Habilidades estadísticas del equipo administrativo de la propiedad
- Nível de desagregación de datos con los que cuenta la propiedad
- Capacidad de cómputo con el que la propiedad cuenta para el cálculo del modelo
- Nível de automatización de procesos dentro de la propiedad, es decir, si cuenta con la capacidad de poder hacer cambios de precios e inventarios en línea

Si bien, en el apartado anterior se presentaron enfoques de vanguardia (modelos de inteligencia artificial y modelos de big data) que toman en cuenta toda la información generada por los sistemas propios del hotel y fuentes externas para ser procesado por un modelo de *caja negra* para obtener un resultado, este tipo de modelos no permiten que el equipo que lo opera comprendan plenamente su funcionamiento, lo cual censura las aportaciones que el equipo pueda hacer para enriquecerlo, es por ello que para fines de este trabajo de investigación utilizaremos un modelo convencional compuesto por dos módulos: un módelo de regresión poisson para el cálculo del pronóstico de la demanda, y un módelo de maximización sujeto a restricciones para el cálculo de precios óptimos por día de reservación.

El primer módulo pronósticará la demanda utilizando datos para un hotel de negocios ubicado en una de las avenidas más importantes de la Ciudad de México. El set de datos con el que se contó durante esta investigación contenía el detalle de cada una de las reservaciones realizadas para esta propiedad desde 2014 hasta el 11 de agosto de 2018.

El segundo módulo asignará los precios óptimos para un tipo de habitación estándar tomando en cuenta los días de antelación con los que se reserva una

habitación en la propiedad, de tal forma que al finalizar el proceso se cuente con una matriz de días de antelación vs precio óptimo.

En los apartados posteriores se explicará a detalle la construcción del módelo propuesto y los resultados obtenidos.

## Capítulo 3

# Metodología

En el presente capítulo se presentará la metodología utilizada para la creación de un módulo propuesto para la predicción de demanda y maximización de ingresos en hoteles. La metodología guiará la estructura de este trabajo con el fin de hacer de él una contribución científica. La presente investigación se puede dividir en dos partes. La primera, consistió en el desarrollo un modelo capaz de predecir la demanda y ofrecer recomendaciones de precios para maximizar el ingreso diario de una propiedad. La segunda parte consistió en probar dicho modelo y discutir los resultados obtenidos con la finalidad de abrir nuevas líneas de investigación.

## Diseño del modelo

Para poder construír un modelo de predicción de demanda y maximización de ingresos para los hoteles que fueron sujetos al estudio, se siguieron una serie de pasos descritos a continuación:

### Entendimiento del negocio

El primer paso durante la construcción del modelo fue el entendimiento del negocio ya que para poder interpretar los datos es necesario comprender el negocio que está implicito en los datos. Durante esta etapa se trabajó con el

### Capítulo 3: Metodología

equipo de gestión comercial de las propiedades para entender qué datos son analizados durante el proceso de toma de decisiones, de dónde son obtenidos estos datos y qué variables son de mayor interés para el negocio.

### Identificación de las fuentes de datos

Una vez comprendido el negocio y detectadas las variables de interés durante el proceso de la toma de decisiones, se identificaron las fuentes de datos, las cuales son nutridas por dos principales sistemas dentro de las propiedades: la central de reservaciones y el sistema de gestión de la propiedad. El primero es el sistema que sirve para dar servicio a todos los huéspedes que buscan una habitación mediante los canales de reservación disponibles (sitio web, call center, aplicaciones móviles, correos electrónicos, etc) y el segundo es que gestiona la propiedad y da servicio al huésped desde que llega hasta que se retira de la propiedad. Estos sistemas contienen toda la información del proceso desde que se encuentra en estatus de reservación hasta que llega a un estatus de check out.

## Análisis exploratorio de datos

Luego de haber identificado las principales fuentes de datos, se diseñaron los procesos de extracción de información necesarios para obtener los datos que serían utilizados para la construcción del modelo. Para poder entender los datos, se ejecutó un análisis exploratorio de datos, en dónde se pudo observar el comportamiento de las variables de interés, su distribución probabilística, se detectaron temporalidades en los datos, nível de limpieza de datos y datos atípicos que pudieran generar problemas al momento de la implementación del modelo final.

#### Construcción del modelo

Para la construcción del modelo se tuvieron varias iteraciones en el desarrollo. La primera, consistió en el diseño de los procesos *ETL* para la construcción de los sets de datos que alimentan el modelo de pronóstico de demanda. La segunda iteración se enfocó en la construcción del modelo de pronóstico de demanda, durante esta etapa se analizaron distintos enfoques para la definición

### Capítulo 3: Metodología

del modelo, desde la construcción de redes neuronales y regresiones siendo las últimas las elegidas para la construcción del modelo final. Durante la tercera iteración se construyó el modelo de optimización de ingresos. Este modelo toma como datos de entrada los resultados obtenidos por el modelo de predicción de demanda y está definido como un problema de maximización de una función sujeta a distintas restricciones. La última iteración consisitó en la ejecución de el modelo integral para poder medir el desempeño y poder obtener resultados.

## Pruebas y Resultados

Durante esta etapa se ejecutó el modelo para pronósticar la demanda y maximizar los ingresos para un mes posterior a la fecha de ejecución, los resultados fueron comparados con el desempeño real de la propiedad para obtener el MA-PE del modelo construído. En el capítulo de Resultados del presente trabajo se presentarán los detalles de las pruebas ejecutadas y los resultados obtenidos.

## Capítulo 4

# Diseño y Desarrollo

Este capítulo describirá el diseño y desarrollo del modelo de predicción de demanda y optimización de ingresos. El primer paso será presentar los *data sets* utilizados. El segundo paso consistirá en describir el modelo, sus módulos, el funcionamiento y la arquitectura.

## **Data Sets**

## Detalle de reservaciones

Para la construcción del modelo de predicción de demanda se utilizaron tres data sets que contienen la información suficiente para poder hacer un pronóstico efectivo de la demanda de una propiedad.

El primer data set utilizado fue extraído directamente del sistema de gestión de propiedades y contiene información de todas las reservaciones marcadas en los libros de la propiedad, así como la información de las estancias pasadas. A continuación se presenta a detalle la información contenida en este data set, el diccionario de datos y un breve resumen de la información en cada una de las columnas.

### Diccionario de Datos

A continuación se presenta el diccionario de datos del *data set* que contiene la información detallada de las reservaciones:

- rsrv\_code: Código de confirmación de la reservación
- date\_create: Fecha y hora de creación de la reserva
- date\_in: Fecha de llegada a la propiedad
- date\_out: Fecha de salida de la propiedad
- nights: Número de noches de la reservación en el hotel
- prop\_code: Código de la propiedad dentro del sistema de gestión de propiedades
- mkt\_sgm: Segmento de mercado del huésped amparado en la reservación
- Dia\_Sem: Día de la semana de la fecha de llegada del huésped
- rate\_code: Código de tarifa
- bucket: Categoría de tarifa
- Ingresos: Ingresos obtenidos por la renta habitación de la reservación
- rsrv\_src: Canal de generación de la reservación
- rsrv\_type: Tipo de reservación
- room\_type: Tipo de habitación
- PAX: Número de personas amparadas por la reservación

#### Resumen de datos

## rsrv\_code date\_create

## Min. :6265739 Min. :2016-07-20 18:31:59 ## 1st Qu.:7499788 1st Qu.:2017-03-27 10:10:09

## Median :7999769 Median :2017-06-30 12:12:57

```
:8007253
                              :2017-06-27 13:38:02
##
    Mean
                       Mean
    3rd Qu.:8505582
##
                       3rd Qu.:2017-09-27 13:22:36
##
    Max.
           :9053354
                       Max.
                              :2018-01-01 03:08:21
##
       date_in
##
    Min.
           :2017-01-01 00:00:00
    1st Qu.:2017-04-04 00:00:00
##
    Median :2017-07-06 00:00:00
##
           :2017-07-06 02:18:17
##
    Mean
    3rd Qu.:2017-10-08 00:00:00
##
    Max.
           :2017-12-31 00:00:00
##
##
       date_out
                                        nights
##
           :2017-01-02 00:00:00
                                   Min.
                                           :1
    1st Qu.:2017-04-05 00:00:00
                                    1st Qu.:1
##
    Median :2017-07-07 00:00:00
                                   Median:1
##
    Mean
           :2017-07-07 02:18:17
                                   Mean
##
                                           :1
    3rd Qu.:2017-10-09 00:00:00
                                   3rd Qu.:1
##
##
    Max.
           :2018-01-01 00:00:00
                                   Max.
                                           :1
##
     prop_code
                          mkt_sgm
                                              Dia_Sem
    Length: 44391
                        Length: 44391
                                            Length: 44391
##
    Class : character
                        Class :character
                                            Class : character
##
##
    Mode :character
                        Mode :character
                                            Mode :character
##
##
##
##
     rate_code
                           bucket
                                               Ingresos
    Length: 44391
                        Length: 44391
                                            Min. : 0
##
                        Class :character
                                            1st Qu.:1200
    Class :character
##
    Mode :character
                        Mode :character
                                            Median:1462
##
                                                   :1449
##
                                            Mean
                                            3rd Qu.:1658
##
##
                                            Max.
                                                   :3900
##
      rsrv_src
                         rsrv_type
                                             room_type
    Length: 44391
                        Length: 44391
                                            Length: 44391
##
    Class :character
                        Class : character
                                            Class : character
```

```
##
    Mode
          :character
                        Mode :character
                                            Mode :character
##
##
##
##
         pax
##
    Min.
            :0.000
##
    1st Qu.:1.000
    Median :1.000
##
    Mean
            :1.271
##
    3rd Qu.:1.000
##
##
    Max.
            :5.000
```

Es importante resaltar que los datos fueron trabajados para presentarse de manera desagregada, es decir, si una reservación ampara una estancia de 5 noches, en el *data set final* se presenta un registro por cada noche de la estancia, por ejemplo:

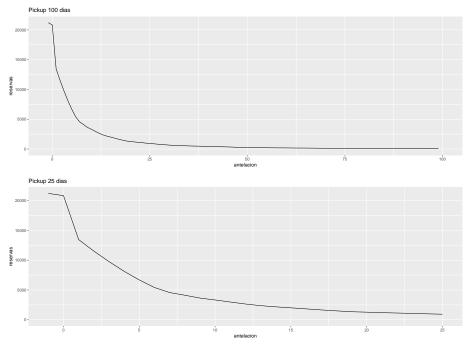
rsrv_code	date_create	date_in	date_out	nights	room_type
6265739	2016-07-20 18:31:59	2017-04-07	2017-04-08	1	NSK
6265739	2016-07-20 18:31:59	2017-04-08	2017-04-09	1	NSK
6265739	2016-07-20 18:31:59	2017-04-09	2017-04-10	1	NSK
6265739	2016-07-20 18:31:59	2017-04-10	2017-04-11	1	NSK
6265739	2016-07-20 18:31:59	2017-04-11	2017-04-12	1	NSK
6265739	2016-07-20 18:31:59	2017-04-12	2017-04-13	1	NSK

Como se puede observar, el número de reservación es el mismo en los seis registros, lo mismo ocurre con la fecha de creación, las noches y el tipo de habitación, sin embargo, la fecha de entrada y la fecha de salida va cambiando en cada registro.

## Curvas de Pickup

Del data set anterior podemos obtener las curvas de pickup del hotel. Estas curvas describen el comportamiento de las reservaciones para la propiedad en cuestión ya que mediante ellas podemos saber con cuanto tiempo de antici-

pación los huéspedes comienzan a reservar una habitación en la propiedad. A continuación se muestran las curvas de pickup para esta propiedad:



Analizando las gráficas presentadas anteriormente podemos concluír que la demanda de esta propiedad comienza 25 días antes de la llegada del huésped al hotel, e incrementa considerablemente 5 días antes de la llegada del huésped al hotel. Este dato nos indica que el huésped comienza a buscar una habitación dentro de esta propiedad en un lapso no mayor a 25 días antes de emprender su viaje.

Las curvas de *pickup* son importantes dentro del proceso de toma de decisiones ya que le indican al equipo que gestiona la propiedad el tiempo de antelación con el cual deberían llevar a cabo las acciones necesarias para poder optimizar el ingreso generado por la renta de habitaciones.

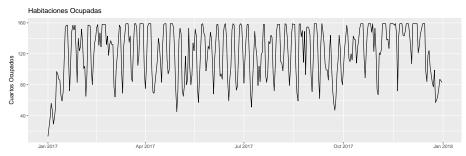
## Ocupación de la propiedad

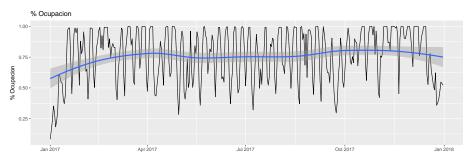
El segundo data set con el que se trabajó contiene las líneas de tiempo de los níveles de ocupación de la propiedad. Este set de datos es de suma importancia ya que proporciona información relevante con respecto a las temporalidades del

hotel, mismas que deben ser reflejadas en el resultado del modelo.

Las temporalidades del hotel pueden ser desde periodos con alta o baja ocupación, inclusive por día de la semana ya que al ser un hotel enfocado a viajes de negocio, se esperaría tener una alta ocupación los días laborales (Lunes a Jueves) y una baja ocupación los fines de semana (Viernes a Domingo).

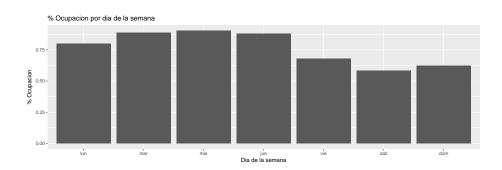
A continuación se presentan un par de gráficas que describen el contenido del  $data\ set$  en cuestión:





Como se puede observar en las gráficas presentadas anteriormente, esta propiedad tiene niveles de ocupación alrededor del  $75\,\%$  llegando en repetidas ocasiones al  $100\,\%$  de ocupación. Las caídas en los níveles de ocupación ocurren los fines de semana, lo cual confirma que el mercado objetivo de la propiedad estudiada es el turismo de negocios.

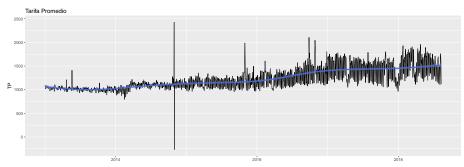
A continuación se presenta una gráfica de níveles de ocupación por día de la semana:



## Tarifa Promedio de la propiedad

El tercer conjunto de datos utilizado contiene los valores de la tarifa promedio *ADR: Average Daily Rate* en el tiempo. Estos datos fueron obtenidos directamente del PMS y es el resultado de sumar los ingresos generados por las habitaciones divididos por el número total de cuartos vendidos.

A continuación se presenta la línea de tiempo con los valores para la tarifa promedio a lo largo del tiempo.



De esta última gráfica se puede observar que los precios siguen una tendencia positiva con respecto al tiempo, a medida que pasa el tiempo, los precios incrementan, sin embargo podemos notar también que a medida que pasa el tiempo los precios varían más. Si contrastamos la información presentada en la gráfica de la tarifa promedo vs el tiempo y la presentada en la gráfica de ocupación vs el tiempo podemos ver que aunque los precios han aumentado en esta propiedad, las tendencias en los níveles de ocupación permanecen constantes.

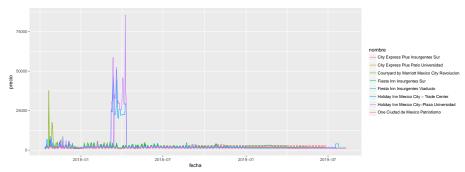
## Precios Públicos en el tiempo

Como se mencionó anteriormente, una propiedad típicamente tiene diferentes precios disponibles para cada uno de los segmentos de mercado a los que atiende. La tarifa que se ofrece al público que llega al hotel sin una reservación previa se le conoce como tarifa pública y generalmente es la tarifa con el precio mas alto de la cúal desprenden todas las demás tarifas, es decir, el conjunto de tarifas disponible en el hotel serán descuentos realizados sobre la tarifa pública.

El tercer data set con el se trabajo el desarrollo del modelo contiene la información de las tarifas públicas para el hotel en cuestión y su competencia a lo largo del tiempo. Esto nos ayudará a conocer el precio del producto ofrecido en el mercado objetivo, de tal forma que los precios arrojados por el modelo se encuentren siempre dentro del mercado.

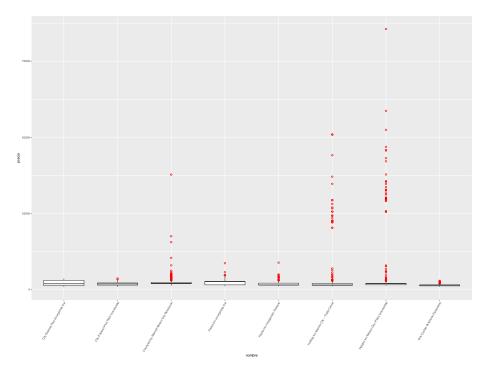
Los precios de la competencia fueron obtenidos de las páginas electrónicas de las agencias en línea, booking.com y expedia.com principalmente.

A continuación se presentan las líneas de tiempo con los precios públicos para el conjunto de propiedades.



En la gráfica anterior se puede observar que hay algunos datos atípicos ya que es poco probable encontrar habitaciones en este segmento de hoteles por arriba de los \$3,000 MXN. Para confirmar esto se realizó una gráfica de caja y bigotes (boxplot) en la cuál se puede observar a primera vista los datos atípicos contenidos en el data set.

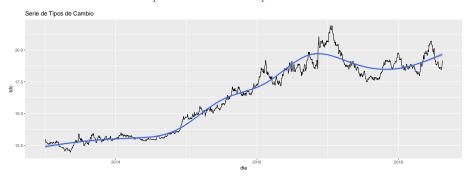
Capítulo 4: Diseño y Desarrollo



Los datos atípicos fueron eliminados antes de proceder a trabajar con el módelo final.

## Tipo de cambio

El último data set utilizado para la construcción del modelo contiene la información histórica de los tipos de cambio del peso frente al dólar.



En el siguiente apartado detallaremos cómo se utilizaron los datos presentados para la construcción del modelo de predicción de demanda y maximización de

ingresos.

## Modelo de Predicción de Demanda

El modelo de predicción de demanda toma como entrada los datos de las curvas de *pickup* para el hotel para cada día del periodo estudiado. Estas curvas describen la velocidad con la que una propiedad vende su inventario para un día en específico de tal forma que el modelo propuesto pueda ajustar una curva que resuma el comportamiento de la propiedad en un día similar al estudiado y de esta forma se pueda generar unna predicción de los cuartos vendidos en la propiedad y los días de antelación con los que serán vendidos.

Este modelo está compuesto por dos módulos principales. El primero es una regresión Poisson definida como  $log(E(Y|X)) = \beta_0 + \beta_1 X$ , que se alimentará con las curvas de pickup que describen el comportamiento del hotel. Cómo resultado de este módulo obtendremos un parámetro  $\beta_0$  y un parámetro  $\beta_1$  que describen la curva que mejor ajusta al pickup del hotel.

A continuación se muestra un resumen del conjunto de datos que alimentan al primer módulo del modelo de predicción de demanda:

<pre>prop_code date_create</pre>		date_in nights	antelacion		
1	CEINS	2017-03-25	2017-03-26	1	1
2	CEINS	2016-12-26	2017-01-01	3	6
3	CEINS	2016-12-26	2017-01-02	3	7
4	CEINS	2016-12-26	2017-01-05	1	10
5	CEINS	2016-12-26	2017-01-03	1	8
6	CEINS	2016-12-26	2017-01-04	1	9
7	CEINS	2016-12-26	2017-01-05	1	10
8	CEINS	2016-12-26	2017-01-01	1	6
9	CEINS	2016-12-26	2017-01-02	1	7
10	CEINS	2016-12-26	2017-01-03	1	8
11	CEINS	2016-12-26	2017-01-04	1	9
12	CEINS	2016-12-27	2017-01-02	1	6
13	CEINS	2016-12-27	2017-01-03	1	7
14	CEINS	2016-12-27	2017-01-03	1	7

### 15 CEINS 2016-12-27 2017-01-04 1 8

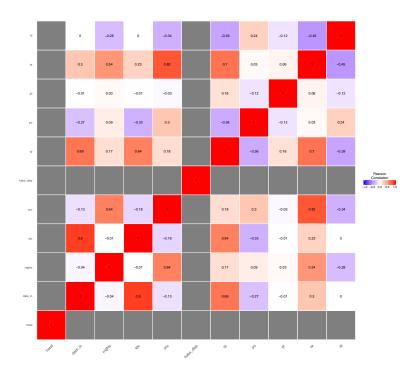
Una vez obtenidos los parámetros  $\beta_0$  y  $\beta_1$  de la regresión *Poisson*, se procede a generar predictores potenciales de la demanda a partir de los datos con los que contamos para este análisis.

Los predictores definidos son:

- diaSem: Definido como factores que van de Lunes a Domingo
- Mes: Definido como factores que van de Enero a Diciembre
- Eventos: 1 si la plaza cuenta con algun evento social, deportivo, o de entretenimiento en esa fecha, 0 en caso contrario
- PT: Definido como la tarifa promedio de la propiedad dividida entre la tarifa promedio de la competencia
- TDC: El valor del peso frente al dólar para cada día
- $\bullet$   $beta_0$ : El parámetro  $\beta_0$  obtenido de la regresión Poisson
- $\bullet$   $beta_1 :$  El parámetro  $\beta_1$  obtenido de la regresión Poisson

A continuación podemos observar la matriz de correlaciones de los predictores propuestos vs la ocupación de la propiedad (esto debe cambiar, se debe correlacionar los predictores vs la  $\beta_0$  y  $\beta_1$ )

Capítulo 4: Diseño y Desarrollo



Con estos predictores definidos se procede a alimentar una regresión lineal que calculará nuevos parámetros  $\beta_{0*}$  y  $\beta_{1*}$ . A partir de estos nuevos parámetros se construyen las curvas de *pickup* que ayuden a predecir la demanda de la propiedad en días futuros.

Una vez concluído el cálculo, se genera una matriz en la cuál se plasma la estimación del número de *cuartos* que se venderán en una ventana futura:

	dia	cn_predic		
	<date></date>	<int></int>		
1	2018-06-01	92		
2	2018-06-02	78		
3	2018-06-03	96		
4	2018-06-04	99		
5	2018-06-05	132		
6	2018-06-06	151		
7	2018-06-07	138		
8	2018-06-08	88		
9	2018-06-09	77		

## Deluxe King, 32 rooms city view

\$110	\$110	\$110	\$110	\$110	\$110	\$110	\$110
\$110	\$110	\$110	\$110	\$120	\$120	\$120	\$120
\$120	\$120	\$120	\$120	\$130	\$130	\$130	\$130
\$130	\$130	\$130	\$155	\$155	\$155	\$155	\$155

Figura 4.1: Asignacion de inventario

10 2018-06-10 109

Esta matriz será la entrada del modelo que recomendará los precios por habitación para maximizar los ingresos de la propiedad.

## Modelo de maximización de ingresos

Una vez pronósticado el nível de ocupación para cada una de las propiedades de la cadena, se alimentó un modelo de pricing dinámico que entrega recomendaciones de precios para la tarifa pública tomando en cuenta la demanda pronósticada para cierto día del año.

Típicamente el gerente de la propiedad controla la cantidad de cuartos ofrecidos a diferentes precios, es decir, se asigna cierto número de cuartos a cada nível de tarifa de tal forma que cuando el inventario asignado al precio mas bajo se agota, se consume el inventario asignado al siguiente nivel de tarifa que será mayor al primer precio ofertado.

A continuación se muestra un esquema donde se ejemplifica la idea mencionada anteriormente:

Como se puede observar, tenemos un inventario de 32 cuartos divido en 4 níveles

de precios:

- 12 cuartos son ofrecidos a un valor de 110 USD
- 8 cuartos son ofrecidos a un valor de 120 USD
- 7 cuartos son ofrecidos a un valor de 130 USD
- 5 cuartos son ofrecidos a un valor de 155 USD

## Formulación del modelo

Un problema de maximización de ingresos es básicamente un problema de optimización sujeto a restricciones, en este caso, se quiere maximizar la siguiente función objetivo:

$$\sum_{n=0}^{n} p_i * o_i$$

En donde i es la índice de la noche,  $p_i$  es el precio del cuarto para la i-ésima noche y  $o_i$  es la ocupación pronósticada (demanda) para la i-ésima noche al precio  $p_i$ . Asumimos también que la función de la ocupación (demanda) está sujeta al precio bajo la siguiente relación:

$$o = o_{nominal} * (\frac{p}{p_{nominal}})^e$$

Donde  $o_{nominal}$  corresponde a la ocupación pronosticada para una noche dada tomando como base un precio nominal  $(p_{nominal})$ . Para este caso el  $p_{nominal}$  es igual a la tarifa pública promediada a lo largo del año. El valor de e (elasticidad) toma un valor = -2. En otras palabras, p incrementa en un 10 % y la demanda decrece cerca de un 20 %.

Existen las siguientes restricciones también:

$$o_i < Capacidad \ \forall i$$

У

$$p_i > 0 \ \forall i$$

En otras palabras, la ocupación no puede exceder a la capacidad del hotel y los precios deben ser siempre mayores a cero.

Para poder hacer una asignación dinámica de los precios, evitando tener que correr el modelo conforme la información del hotel es actualizada, se partió el

inventario en 4 níveles de disponiblidad (159,120,80 y 40 cuartos disponibles). Para cada nível de capacidad se resolvió la función objetivo para obtener 4 conjuntos de precios, de esta forma, el gerente de la propiedad puede saber a qué nível de precio debe subir la tarifa pública de la propiedad conforme las habitaciones disponibles decrecen.

El modelo de maximización de ingresos arroja como resultado una matriz de día vs precio por niveles de inventario. A continuación se muestra un ejemplo:

```
##
              day
                        40
                                          120
                                                    159
## 137 2018-05-17 1616.650 1374.773 1122.4972
      2018-03-18 1701.113 1675.709 1368.2105 1188.6253
      2018-02-21 1666.334 1529.706 1248.9996 1085.0615
## 52
      2018-01-16 1647.043 1463.557 1194.9895 1038.1406
## 16
## 24
      2018-01-24 1702.217 1681.071 1372.5888 1192.4289
      2018-04-03 1703.315 1686.416 1376.9532 1196.2205
## 93
      2018-03-19 1621.479 1387.804 1133.1372 984.4067
## 167 2018-06-16 1498.239 1138.420
                                    929.5160 807.5119
## 139 2018-05-19 1527.223 1184.905
                                     967.4709 840.4850
## 174 2018-06-23 1518.070 1169.615 954.9869 829.6396
```

### Consideraciones del modelo

Este modelo se formuló considerando los siguientes puntos:

- Se consideran estancias de una sola noche
- No se toman en cuenta reservaciones para grupos ni cancelaciones
- Asusmimos paridad de precios entre los canales, es decir, los precios no varían entre los canales de venta
- Se considera solamente un tipo de habitación, el incremento por cambio de habitación es un monto fijo conocido como gap
- Se asume un valor para la elasticidad (-2) que es un valor razonable para la industria

En el siguiente capítulo se discutirá acerca de la interpretación del modelo propuesto y los resultados obtenidos.

## Capítulo 5

# Interpretación y Resultados

En el presente capítulo se presentarán a detalle los resultados obtenidos por el módelo de pronóstico de demanda y maximización de ingresos. También se discutirá la forma en la que se deberán interpretar los resultados del mismo y así evitar sacar conclusiones erróneas o fuera de contexto.

## Interpretación del modelo

Como hemos mencionado en capítulos anteriores, el modelo propuesto se compone de dos módulos principales, el primero de ellos se encarga de pronósticar la demanda de cuartos noche para un día dado con cierto tiempo de anticipación, mientras que el segundo módulo toma esa información y cálcula los precios por habitación que maximizan el ingreso de la propiedad tomando en cuenta las restricciones definidas.

A continuación explicaremos detalladamente las salidas obtenidas en cada uno de los módulos definidos, la manera en que se deben interpretar esas salidas y los resultados obtenidos para el desempeño del modelo.

### Capítulo 5: Interpretación y Resultados

### Pronóstico de Demanda

El modelo de pronóstico de demanda toma como entrada las curvas de pickup para una propiedad en específico, información de su ocupación histórica, lineas de tiempo de tarifa promedio, lineas de tiempo de tarifas publicas propias y de la competencia, etc. Al finalizar el procesamiento de la información se obtiene una matriz que contiene, entre otras variables, el parámetro  $\beta_0$  y  $\beta_1$  con el que se puede reconstruír la curva de pickup para un día futuro. De esta manera podemos obtener una buena aproximación de los cuartos que serán vendidos en cierto día y con qué velocidad se realizará esta venta.

A continuación se presenta un extracto de los resultados obtenidos por el modelo de pronóstico de demanda:

```
##
     hotel
                  dia AAbeta0
                                      AAbeta1 AAvariacion
## 1 CEINS 2018-01-01 2.335294 -2.489863e-06
                                                 0.1884625
## 2 CEINS 2018-01-02 2.984073 -2.818019e-06
                                                0.1321997
## 3 CEINS 2018-01-03 3.301841 -3.535574e-06
                                                0.3262416
  4 CEINS 2018-01-04 3.782523 -2.295688e-06
                                                0.1744051
## 5 CEINS 2018-01-05 3.761697 -1.089675e-06
                                                 0.0925871
  6 CEINS 2018-01-06 3.140137 -2.292639e-06
                                                 0.1887511
                   PO
                             PT
##
         tdc
                                   diasem mes eventos1 eventos
## 1 19.7354 0.840382 0.872720
                                                       0
                                                               0
                                    lunes ene.
## 2 19.7354 1.096970 1.025310
                                                       0
                                                               0
                                   martes ene.
## 3 19.6629 0.927171 0.992081 miércoles ene.
                                                       0
                                                               0
## 4 19.4899 1.045640 1.024860
                                                       0
                                                               0
                                   jueves ene.
## 5 19.3717 0.927771 0.953648
                                                               0
                                  viernes ene.
                                                       0
## 6 19.2427 1.334990 0.908828
                                   sábado ene.
                                                       0
                                                               0
     pred.beta0 pred.beta1
##
       3.159533 -0.12278602
## 1
       3.916035 -0.11603131
## 2
       3.874017 -0.10891126
## 3
       4.159721 -0.10283409
## 4
       3.698266 -0.08467446
## 5
       3.771660 -0.09371103
## 6
```

## Capítulo 5: Interpretación y Resultados

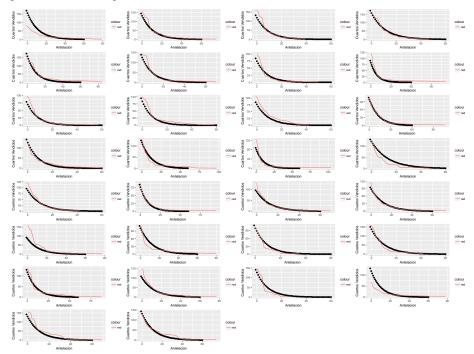
Para poder reconstruír la curva de pickup pronosticada se debe tomar los parámetros pred.beta0 y pred.beta1 para evaluar la siguiente expresión:

$$E[y|x] = e^{\beta_0 + \beta_1 x}$$

Dónde:

- $\bullet$  E[y|x]= El valor esperado de cuartos noches para un día en específico
- $\beta_0 = \text{pred.beta0}$
- $\beta_1 = \text{pred.beta1}$
- x = días de antelación

Evaluando esta expresión en distintas fechas obtenemos las siguientes curvas de pronóstico de ocupación:



Podemos observar que la curva pronosticada tiene un buen ajuste sobre la curva real en la mayoría de los casos.

Para evaluar el desempeño del modelo se utilizó la medida MAPE definida como:

$$MAPE = \frac{1}{n} \sum_{t=1}^{n} |\frac{y_t - h_t}{y_t}|$$

## Capítulo 5: Interpretación y Resultados

## Dónde:

- $\blacksquare \ \ n = N$ úmero de puntos ajustados
- $\bullet \ y_t = \mbox{Cuartos}$ noche vendidos en el tiempo t
- $\bullet \ h_t = \mbox{Venta de cuartos noche pronósticada en el tiempo } t$

# Bibliografía

- [1] El-Gayar N, Hendawi AT, Zakhary A, El-Shishiny H. A proposed decision support model for hotel room revenue management. ICGST Int J Artif Intell Mach Learn 2008.
- [2] Heba Abdel Aziz, Mohamed Saleh, Mohamed H. Rasmy, Hisham ElShishiny Dynamic room pricing model for hotel revenue management systems. Faculty of Computers and Information, Cairo University 2011.
- [3] Gabriel Bitran, Rene Caldentey An Overview of Pricing Models for Revenue Management. Sloan School of Management, MIT, Cambridge, Massachusetts 2011.
- [4] McGill, J. and van Ryzin, G Revenue management: Research overview and Prospects. Transportation Science 1999.
- [5] Cross, R. Revenue Management: Hard-Core Tactics for Market Domination. New York, NY: Broadway Books 1997.
- [6] Marriott, Jr., J. and Cross, R. Room at the revenue inn. In Book of Management Wisdom: Classic Writings by Legendary Managers. Peter Krass, New York, NY: Wiley 2000.
- [7] Weatherford, L. R., Kimes, S. E. A comparison of forecasting methods for hotel revenue management. Cornell University 2003.
- [8] M. J. Beckmann and F. Bobkowski Airline Demand: An Analysis of Some Frequency Distributions. Naval Res. Logistics 1958.

## Bibliografía

- [9] Athanasius Zakharya, Amir F. Atiyab, Hisham El-Shishinyc and Neamat E. Gayara Forecasting hotel arrivals and occupancy using Monte Carlo simulation Faculty of Computers and Information, Cairo University 2009.
- [10] Lee, A. Airline Reservations Forecasting Erewhon, NC: Prentice-Hall 1990.
- [11] Flides, R, Ord, K. Forecasting competitions: their role in improving forecasting practice and research Oxford: Blackwell 2002.
- [12] Ming Tse, Tony S., Tung Poon Yiu Analyzing the use of an advance booking curve in forecasting hotel reservations Taylor and Francis 2015.
- [13] Wickham, R. R. Evaluation of forecasting techniques for short term demand of air transportation MIT Thesis: Fligt Transportation Lab 1995.
- [14] Weatherford, L. R. Forecasting issues in revenue management Springs INFORMS Conference 1998.
- [15] Caicedo-Torres, W., Payares, F. A machine learning model for occupancy rates and demand forecasting in the hospitality industry Universidad Tecnologica de Bolivar 2016.
- [16] Tierney, Heather L.R, Bing Pan A poisson regression examination of the relationship between website traffic and search engine queries Netnomics 2012.
- [17] Pan,B., Yang, Y Forecasting destination weekly hotel occupancy with big data Journal of Travel Research 2017.
- [18] Aziz, et al. Dynamic Pricing for Hotel Revenue Management Using Price Multipliers Faculty of Computers and Information, Cairo University 2011.
- [19] Reaside, R., Windle D. Quantitive aspects of yield management London: Cassell 2000.
- [20] Kin Keng Lai, Wan Lung Ng A stochastic approach to hotel revenue optimization University of Hong Kong 2003.